Benchmark des modèles Ollama — Assistant commercial Givaudan

Équipe Casque · Hackathon Givaudan · 10/11/2026

Modèle retenu : Llama 3.2 (3B), de Meta. C'est le modèle qui respecte le mieux les consignes (il invente moins), qui maîtrise le français et l'anglais, et qui tourne sur un ordinateur portable. Il obtient 86/100 sur notre grille.

1. La mission

Notre solution est un **assistant IA pour les commerciaux de Givaudan**. Avant un rendez-vous, le commercial pose une question, par exemple :

- « Prépare mon rendez-vous avec le client X. »
- « Quels produits puis-je lui proposer ? »
- « Quels points sensibles ont été soulevés lors de la dernière visite ? »

L'assistant fonctionne en deux temps :

1. **Il cherche** les informations utiles dans les documents commerciaux : fiches clients, comptes rendus de visite, catalogue produits.
2. **Il rédige** une réponse claire à partir de ces informations, sans rien inventer.

Chaque étape utilise un modèle d'IA différent. Ce benchmark explique lesquels nous avons choisis, et pourquoi.

2. Pourquoi des modèles Ollama, en local

Tous les modèles comparés tournent **directement sur l'ordinateur**, grâce à l'outil gratuit Ollama. Pour Givaudan, c'est un choix important :

- **Confidentialité** : les données clients ne quittent jamais la machine, aucune information n'est envoyée sur internet.
- **Coût** : aucun abonnement ni paiement à l'usage.
- **Autonomie** : l'assistant fonctionne même sans connexion, par exemple en déplacement chez un client.

La contrepartie : l'ordinateur fait tout le travail. Les modèles doivent donc être assez **légers** pour un PC portable de commercial.

3. Les modèles comparés

Nous avons comparé six modèles de rédaction, gratuits et disponibles sur Ollama.

Modèle	Fabricant	En une phrase
Qwen 2.5 (1.5B)	Alibaba (Chine)	Modèle de départ du projet, très léger
Qwen 2.5 (3B)	Alibaba (Chine)	Version deux fois plus grande du précédent
Llama 3.2 (3B)	Meta (États-Unis)	Petit modèle très répandu, pensé pour les assistants
Phi-4 mini	Microsoft (États-Unis)	Petit modèle fort en raisonnement
Gemma 4 (E2B)	Google (États-Unis)	Modèle récent de Google
Mistral (7B)	Mistral AI (France)	Plus gros, référence de qualité

Le chiffre entre parenthèses est la taille du modèle, en milliards de paramètres. Plus il est grand, plus il est capable, mais plus il est lourd et lent.

4. Comment nous avons jugé

Premier filtre : la taille. Un modèle de plus de 4 Go tourne mal sur un PC portable de 8 Go. Nous avons donc écarté **Gemma 4** et **Mistral**.

Ensuite, une note sur cinq critères, pondérés selon les besoins d'un commercial :

Critère	La question que l'on se pose	Poids
Respect des consignes	Répond-il seulement avec les documents, et dit-il « je ne sais pas » plutôt que d'inventer ?	30 %
Langues	Maîtrise-t-il le français et l'anglais, les deux langues de travail d'un groupe international ?	25 %
Légèreté	Tourne-t-il vite sur le PC portable d'un commercial ?	20 %
Compréhension générale	Comprend-il bien des questions variées ?	15 %
Licence	A-t-on le droit de l'utiliser dans une entreprise comme Givaudan ?	10 %

Le respect des consignes pèse le plus lourd : **un commercial qui reçoit une information inventée sur son client peut perdre sa crédibilité en rendez-vous.** Les notes s'appuient sur les résultats de tests publiés par les fabricants.

5. Résultats

Rang	Modèle	Consignes	Langues	Légèreté	Compréhension	Licence	Note /100
1	**Llama 3.2 (3B)**	Très bon	Très bon	Bon	Moyen	Moyen	**86**
2	Qwen 2.5 (3B)	Bon	Très bon	Bon	Bon	Bloquant	79
3	Phi-4 mini	Bon	Moyen	Moyen	Très bon	Très bon	76
4	Qwen 2.5 (1.5B)	Faible	Bon	Très bon	Faible	Très bon	68

Gemma 4 (E2B) et Mistral (7B) ont été écartés au premier filtre, car trop lourds.

Qwen 2.5 (3B) est deuxième, mais sa licence interdit l'usage commercial : il ne peut pas être déployé chez Givaudan.

6. Le modèle de recherche

La première étape, retrouver les bonnes fiches, utilise un second modèle, dit « d'embeddings ». Il transforme les textes en données comparables pour retrouver ceux qui répondent à la question.

Nous gardons **nomic-embed-text**, le modèle du projet de départ : il est léger, gratuit et disponible sur Ollama. Si les documents de Givaudan sont surtout en français, nous testerons aussi un modèle de recherche multilingue pour vérifier qu'il retrouve mieux les bonnes fiches.

7. Notre choix : Llama 3.2 (3B)

- **Il suit le mieux les consignes.** C'est le meilleur des modèles comparés sur ce point, au niveau d'un modèle presque trois fois plus gros. Il invente donc moins, ce qui est essentiel face à un client.
- **Il maîtrise le français et l'anglais.** Ce sont deux de ses langues officielles.
- **Il est léger.** Environ 2 Go : il tourne sur un ordinateur portable classique.
- **Il peut être utilisé en entreprise**, ce qui n'est pas le cas de Qwen 2.5 (3B).

Ce que l'on accepte en le choisissant : une compréhension générale un peu plus faible que Phi-4 mini. C'est peu gênant ici, car les réponses viennent des documents de Givaudan, pas de ce que le modèle sait déjà.

Plan B : sur un ordinateur qui manque de mémoire, Qwen 2.5 (1.5B), deux fois plus léger mais moins fiable.

Le changer dans le projet ne demande de modifier qu'une ligne de configuration.

8. Limites et prochaines étapes

- **Des tests publiés, pas encore les nôtres.** Prochaine étape : faire passer les modèles sur nos propres questions commerciales, avec un script déjà prêt dans le dépôt. Si un autre modèle fait mieux en pratique, nous changerons.
- **L'importance des critères joue.** Si tous les critères comptaient autant, Llama 3.2 et Phi-4 mini seraient à égalité. Nous avons privilégié le respect des consignes, essentiel pour un commercial.

- **Des données réelles.** La démo utilisera des fiches clients fictives ; un vrai déploiement demandera de refaire le test sur les documents de Givaudan.

Sources

- Projet de départ : github.com/hmicn/example-rag
- Llama 3.2 (langues, respect des consignes) : huggingface.co/blog/llama32
- Comparatif Phi-4 mini, Llama 3.2, Qwen 2.5 : build.nvidia.com/microsoft/phi-4-mini-instruct/modelcard
- Qwen 2.5 (licences par taille) : qwenlm.github.io/blog/qwen2.5-llm
- Catalogue des modèles : ollama.com/library