Benchmark des modèles Ollama

Assistant IA pour les commerciaux de Givaudan

Modèle retenu : **Llama 3.2 (3B) · 86/100**

Équipe Casque · Hackathon Givaudan · 10/11/2026

En bref : Llama 3.2 (3B) l'emporte

86

/100 sur notre grille pondérée

Meta · ~2 Go · tourne sur un PC portable

Respecte le mieux les consignes

Invente moins : il répond à partir des documents.

Bilingue français / anglais

Deux de ses langues officielles.

Léger

Environ 2 Go, adapté au PC d'un commercial.

Licence compatible entreprise

Utilisable chez Givaudan, contrairement à Qwen 2.5 (3B).

La mission : préparer chaque rendez-vous client

Avant un rendez-vous, le commercial demande :

> *Prépare mon rendez-vous avec le client X.*

> *Quels produits puis-je lui proposer ?*

> *Quels points sensibles ont été soulevés lors de la dernière visite ?*

L'assistant répond en deux temps

1. Chercher

Trouve les infos utiles dans les fiches clients, comptes rendus de visite et le catalogue produits.

Modèle d'embeddings

2. Rédiger

Écrit une réponse claire à partir de ces informations, sans rien inventer.

Modèle de rédaction (LLM)

Pourquoi des modèles Ollama, en local

Tous les modèles tournent directement sur l'ordinateur grâce à Ollama, outil gratuit.

Confidentialité

Les données clients ne quittent jamais la machine : rien n'est envoyé sur internet.

Coût

Aucun abonnement, aucun paiement à l'usage.

Autonomie

Fonctionne sans connexion, par exemple en déplacement chez un client.

La contrepartie : l'ordinateur fait tout le travail. Les modèles doivent rester assez légers pour un PC portable de commercial.

Six modèles gratuits comparés

Qwen 2.5 (1.5B)

Alibaba · Chine

Modèle de départ du projet, très léger

Qwen 2.5 (3B)

Alibaba · Chine

Version deux fois plus grande du précédent

Llama 3.2 (3B)

Meta · États-Unis

Petit modèle très répandu, pensé pour les assistants

Phi-4 mini

Microsoft · États-Unis

Petit modèle fort en raisonnement

Gemma 4 (E2B) Trop lourd

Google · États-Unis

Modèle récent de Google

Mistral (7B) Trop lourd

Mistral AI · France

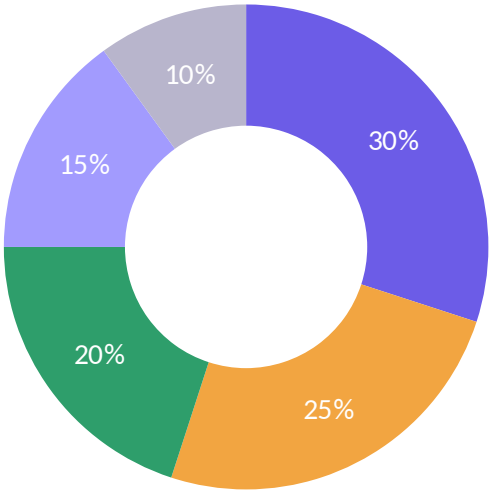
Plus gros, référence de qualité

Le chiffre entre parenthèses = taille en milliards de paramètres. Plus il est grand, plus il est capable… mais lourd et lent.

Comment nous avons jugé

Filtre n°1 : la taille

> 4 Go = trop lourd pour un PC de 8 Go → Gemma 4 et Mistral écartés



Respect des consignes — 30 %

Répond-il seulement avec les documents, et dit-il « je ne sais pas » plutôt que d'inventer ?

Langues — 25 %

Maîtrise-t-il le français et l'anglais ?

Légèreté — 20 %

Tourne-t-il vite sur le PC portable d'un commercial ?

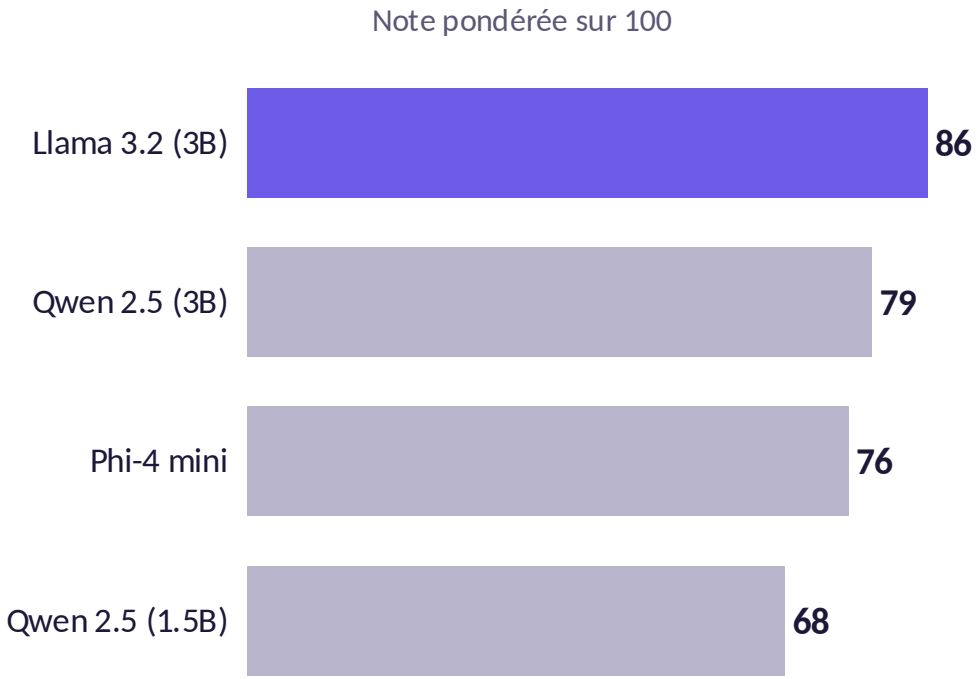
Compréhension générale — 15 %

Comprend-il bien des questions variées ?

Licence — 10 %

A-t-on le droit de l'utiliser chez Givaudan ?

Résultats : Llama 3.2 en tête



Qwen 2.5 (3B) : 2e mais bloqué

Sa licence interdit l'usage commercial : impossible de le déployer chez Givaudan.

Écartés au 1er filtre

Gemma 4 (E2B) et Mistral (7B), trop lourds pour un PC portable.

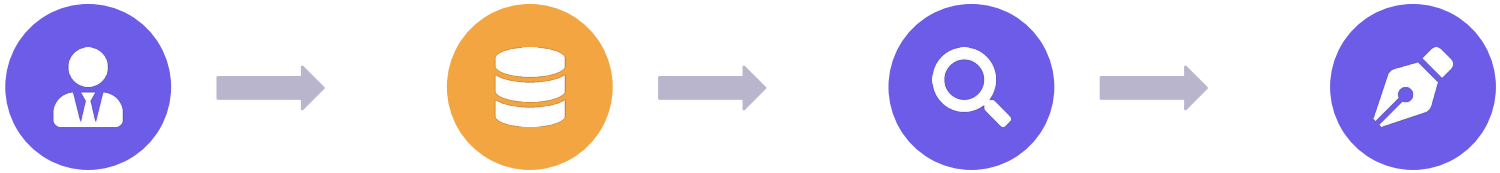
Le détail critère par critère

Rang	Modèle	Consignes 30%	Langues 25%	Légèreté 20%	Compréh. 15%	Licence 10%	Note
1	**Llama 3.2 (3B)**	Très bon	Très bon	Bon	Moyen	Moyen	**86**
2	**Qwen 2.5 (3B)**	Bon	Très bon	Bon	Bon	Bloquant	**79**
3	**Phi-4 mini**	Bon	Moyen	Moyen	Très bon	Très bon	**76**
4	**Qwen 2.5 (1.5B)**	Faible	Bon	Très bon	Faible	Très bon	**68**

Lecture : Llama 3.2 domine sur les deux critères les plus lourds (consignes + langues = 55 % de la note). Sa faiblesse relative, la compréhension générale, compte peu ici.

Le modèle de recherche (embeddings)

Il transforme les textes en données comparables pour retrouver ceux qui répondent à la question.



Choix : nomic-embed-text

Modèle du projet de départ : léger, gratuit, disponible sur Ollama.

Piste à tester

Si les documents de Givaudan sont surtout en français : essayer un modèle de recherche multilingue pour mieux retrouver les bonnes fiches.

Notre choix : Llama 3.2 (3B)

Suit le mieux les consignes

Au niveau d'un modèle presque 3× plus gros : il invente moins face au client.

Français et anglais

Deux de ses langues officielles.

Léger

~2 Go : tourne sur un portable classique.

Utilisable en entreprise

Licence compatible, contrairement à Qwen 2.5 (3B).

Ce que l'on accepte

Une compréhension générale un peu plus faible que Phi-4 mini. Peu gênant : les réponses viennent des documents Givaudan.

Plan B

Qwen 2.5 (1.5B) sur un PC qui manque de mémoire : 2× plus léger, mais moins fiable.

Changement facile

Une seule ligne de configuration à modifier dans le projet.

Limites et prochaines étapes

01

Des tests publiés, pas encore les nôtres

Prochaine étape : faire passer les modèles sur nos propres questions commerciales (script déjà prêt dans le dépôt). Si un autre modèle fait mieux, nous changerons.

02

Le poids des critères compte

À poids égaux, Llama 3.2 et Phi-4 mini seraient à égalité. Nous avons privilégié le respect des consignes, essentiel pour un commercial.

03

Passer aux données réelles

La démo utilise des fiches clients fictives ; un vrai déploiement demandera de refaire le test sur les documents de Givaudan.

Llama 3.2 (3B) : fiable, bilingue, local

Le meilleur équilibre pour un assistant commercial confidentiel et sans abonnement.

Sources

Projet de départ : github.com/hmicn/example-rag
Llama 3.2 : huggingface.co/blog/llama32
Comparatif Phi-4 mini / Llama 3.2 / Qwen 2.5 : build.nvidia.com/microsoft/phi-4-mini-instruct/modelcard
Qwen 2.5 (licences) : qwenlm.github.io/blog/qwen2.5-llm · Catalogue : ollama.com/library